

Grokking модульной арифметики: MLP против spline-KAN

Автор: Варфоломеев Матвей Денисович

Вопрос. Как меняются запоминание и обобщение, если в задаче модульного сложения заменить quadratic MLP на основе архитектуры Громова на spline-KAN сопоставимого размера? Оптимизация адаптирована к сравнению на AdamW; работа строит карту фаз, а не доказывает превосходство KAN.

Протокол. После exploratory-поиска на $p = 97$ зафиксированы критерий и матрица основной серии. Классический grokking требует устойчивого раннего train-запоминания, низкого test в этот момент, плато не менее 1000 шагов и лишь затем устойчивых 99% test. Выполнены 80 запусков: четыре условия, две архитектуры, два weight decay и пять seed; незавершившиеся результаты цензурируются.

Методы. Модели получают one-hot (a, b) и предсказывают $(a + b) \bmod p$ при общих MSE, full-batch AdamW, $lr=0.001$, split и бюджете. В точках запоминания, обобщения и финала измеряются Fourier-диагональная мощность и PCA participation rank. Для пяти KAN зануляются 1%, 5% и 10% top, random и bottom рёбер; random повторяется десять раз.

Главный результат. В полной матрице MLP дала 30/40 классических запусков, KAN — 8/40. Локальный контраст возникает при $p = 31$, 35% train: MLP дала 0/10, KAN — 8/10. При 50% данных KAN обобщалась совместно или со слабой задержкой, а все 20 запусков $p = 53$ получили класс weak delay.

Поддерживающие признаки. У KAN медианная Fourier-концентрация растёт с 0.175 при запоминании до 0.952 в финале. Удаление 10% рёбер меняет test accuracy на -0.078 для top, -0.047 для random и 0.000 для bottom. Top сильнее bottom в 5/5 моделей, но сильнее random-медианы лишь в 4/5.

Проверка вывода. $p = 97$ исключён после exploratory-этапа: его кривые не показывали убедительного grokking. Строгий критерий изменил класс части 99%-запусков. На symmetry-safe split KAN дала 0/5, а MLP в своём режиме $p = 31$, 50% — 5/5: результат KAN зависит от split.

Воспроизводимость. Репозиторий фиксирует критерий фаз, матрицу, конфигурации, истории всех запусков и отрицательные результаты. Итоговые таблицы строятся непосредственно из сохранённых метрик; контрольные суммы позволяют проверить состав комплекта.

Ограничения. Пять seed дают широкие Wilson intervals; Fourier-структура не доказывает единственный алгоритм; сплайн вне наблюдавшихся one-hot значений не интерпретируется. Сохранены код, 80 историй и таблицы.