

Самостоятельная исследовательская работа

Grokking модульной арифметики:

парное сравнение quadratic MLP и spline-KAN

Научный отчёт

Автор: Варфоломеев Матвей Денисович

Задача	$y = (a + b) \bmod p$
Основная серия	80 запусков, seed 10--14
Архитектуры	quadratic MLP на основе Громова и spline-KAN
Среда	Python 3.12, PyTorch 2.7.1
Год	2026

Краткий результат. KAN не ускоряет grokking универсально, а сдвигает границы между фазами обучения.

1. Аннотация и исследовательский вопрос

Grokking --- это позднее обобщение после раннего запоминания и долгого плато. Работа проверяет, как эта последовательность меняется при замене минимальной quadratic MLP на основе архитектуры Громова на spline-KAN сопоставимого размера. One-hot данные, MSE, full-batch AdamW и seed общие. После exploratory-поиска зафиксирована подтверждающая матрица из 80 запусков: модули 31 и 53, четыре сочетания модуля и доли данных, две архитектуры и два weight decay. В статистику входят все кривые.

Главный вывод. В полной матрице MLP дала 30/40 классических запусков, KAN --- 8/40. Локальный контраст возникает при $p = 31$, 35% train: MLP дала 0/10, KAN --- 8/10. При 50% данных KAN обобщалась совместно или со слабой задержкой, а все 20 запусков $p = 53$ получили класс weak delay.

KAN не объявляется лучшей архитектурой, а высокая точность --- пониманием арифметики. Вывод ограничен исследованными моделями, split и бюджетом.

2. Контекст и литература

Power et al. описали позднее обобщение на малых алгоритмических датасетах; Nanda et al. связали скачок test accuracy с постепенной Fourier-динамикой. Gromov предложил минимальную bias-free quadratic MLP с MSE и аналитическими feature maps для модульной арифметики. Park et al. используют Kolmogorov--Arnold representation для переноса весов в transformer, но это не реализованный здесь spline-KAN.

KAN заменяет вес ребра обучаемой одномерной функцией. Это контролируемое вмешательство: меняется вычислительный блок, данные и критерий фаз --- нет.

Разделение частей работы:

- архитектурная основа -- bias-free quadratic MLP, one-hot и MSE из постановки Громова;
- адаптация -- общий full-batch AdamW для контролируемого сравнения;
- расширение -- парный spline-KAN и многосидовый механистический анализ.

3. Данные, модели и функция потерь

Для простого p используются все p^2 пар $(a, b) \in \mathbb{Z}_p^2$. Вход имеет вид

$$x = [\text{onehot}(a), \text{onehot}(b)] \in \mathbb{R}^{2p}, \quad y = \text{onehot}((a + b) \bmod p) \in \mathbb{R}^p.$$

Основная серия использует случайный split; фактическая доля train сохраняется, поскольку число примеров целое.

3.1. Quadratic MLP

MLP не содержит bias. Для ширины $h = 128$:

$$f(x) = \frac{1}{h} W_2 \left(\frac{W_1 x}{\sqrt{2p}} \right)^2.$$

Нормировки, отсутствие bias и активация следуют архитектуре Громова. Его точный gradient-descent протокол здесь не воспроизводится: оптимизатор основной матрицы --- AdamW.

3.2. Spline-KAN

KAN имеет два слоя и ширину 14. Каждое направленное ребро вычисляет

$$\phi(x) = w_{\text{base}} \text{SiLU}(x) + \sum_k w_k B_k(x),$$

где B_k --- фиксированные кубические B-spline basis functions; оба набора коэффициентов обучаются. При `grid_size=5` и `spline_order=3` числа параметров MLP/KAN равны 11,904/11,718 для $p = 31$ и 20,352/20,034 для $p = 53$.

3.3. Оптимизация

Loss --- средний квадрат расстояния до one-hot цели:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N \|f(x_i) - y_i\|_2^2.$$

Парные запуски используют full-batch AdamW, learning rate 0.001, weight decay 0.1 или 0.3 и обучение без досрочной остановки.

4. Строгий критерий grokking и протокол

Сначала exploratory-этап проверял $p = 97$ и помог уточнить постановку. Затем, до просмотра результатов новой серии, были зафиксированы критерий ниже, матрица и seed. Поэтому подтверждающей является серия из 80 запусков, а не весь проект.

99% test accuracy недостаточно. Метка `classical_grokking` требует:

1. train accuracy не ниже 0.99 на пяти последовательных измерениях;
2. test accuracy в начале устойчивого запоминания не выше 0.20;
3. разрыв train--test в этой точке не меньше 0.50;
4. до достижения 0.90 test accuracy проходит не менее 1000 шагов;
5. затем test accuracy устойчиво достигает 0.99.

Другие классы: слабая задержка, совместное обобщение, запоминание без обобщения и отсутствие запоминания. Незавершившийся запуск цензурируется, но остаётся в знаменателе.

Таблица 1: Подтверждающая матрица, зафиксированная после exploratory-этапа.

Модуль и train	Бюджет	Модели	Weight decay
$p = 31, 35\%$	15,000	MLP, KAN	0.1, 0.3
$p = 31, 50\%$	15,000	MLP, KAN	0.1, 0.3
$p = 53, 30\%$	20,000	MLP, KAN	0.1, 0.3
$p = 53, 35\%$	20,000	MLP, KAN	0.1, 0.3

Каждая ячейка использует seed 10--14 и измерения раз в 100 шагов. Для фаз приводится Wilson 95% interval; для задержки --- медиана, диапазон и число обобщившихся запусков.




Рис. 1: Пример классического grokking в новой серии: MLP, $p = 31, 50\%$, $wd=0.1$, seed 10.

5. Парная фазовая карта




Рис. 2: Все пять seed каждой ячейки классифицированы одним и тем же критерием.

Таблица 2: Сжатая сводка фаз. Полные Wilson intervals находятся в `results/tables/paired_summary.csv`.

Модель	p	Train	WD	Classical	Другие фазы	Обобщились
KAN	31	0.35	0.1	4/5	1 без обобщения	4/5; 4.6k
KAN	31	0.35	0.3	4/5	1 без обобщения	4/5; 2.8k
KAN	31	0.50	0.1	0/5	weak 4, joint 1	5/5; 0.4k
KAN	31	0.50	0.3	0/5	weak 2, joint 3	5/5; 0.2k
KAN	53	0.30	0.1	0/5	weak 5	5/5; 3.9k
KAN	53	0.30	0.3	0/5	weak 5	5/5; 2.6k
KAN	53	0.35	0.1	0/5	weak 5	5/5; 2.3k
KAN	53	0.35	0.3	0/5	weak 5	5/5; 1.6k
MLP	31	0.35	0.1	0/5	5 без обобщения	0/5
MLP	31	0.35	0.3	0/5	5 без обобщения	0/5
MLP	31	0.50	0.1	5/5	--	5/5; 5.1k
MLP	31	0.50	0.3	5/5	--	5/5; 5.3k
MLP	53	0.30	0.1	5/5	--	5/5; 10.3k
MLP	53	0.30	0.3	5/5	--	5/5; 13.4k
MLP	53	0.35	0.1	5/5	--	5/5; 6.2k
MLP	53	0.35	0.3	5/5	--	5/5; 7.2k

Главной является эта таблица, а не исторические удачные кривые. Сравнение парное по p , train и weight decay и не переносится на другие модели или задачи. Wilson 95% intervals равны 0.376--0.964 для 4/5 и 0.566--1.000 для 5/5: повторяемость видна, но оценка вероятности широка.

6. Задержка и цензурирование




Рис. 3: Точки -- отдельные seed, оранжевая линия -- медиана наблюдавшихся задержек, красные треугольники -- правое цензурирование.

Задержка идёт от устойчивого train-запоминания до устойчивого test-обобщения. Если обобщение не наступило, время наблюдения показывается как цензурированное и не входит в медиану, поэтому модели с меньшим числом успешных seed не получают искусственного преимущества.

7. Многосидовая Fourier- и PCA-динамика

Для $p = 31$, 35% train, $wd=0.3$ сохранены состояния запоминания, обобщения и финала. Логиты каждого класса образуют таблицу $p \times p$; двумерный FFT измеряет долю мощности на $f_a = f_b$ без DC-компоненты.




Рис. 4: Fourier-динамика всех доступных фаз. У MLP в этом условии точка обобщения отсутствует, поскольку пять запусков цензурированы.

Медиана KAN растёт с 0.175 при запоминании до 0.828 при обобщении четырёх seed и 0.952 в финале. У MLP она растёт с 0.075 до 0.527 без строгого test-порога. Поэтому Fourier-концентрация --- progress measure, а не критерий grokking. Participation rank, эффективное число направлений дисперсии скрытого слоя, меняется неодинаково между seed и служит только диагностикой.

Полный средний classwise-спектр сохранён для каждой пары частот (f_a, f_b) , каждого seed и checkpoint. Ведущие моды вынесены в отдельную таблицу; это позволяет проверить волновую структуру, а не только один диагональный показатель.




Рис. 5: Медианный по seed полный Fourier-спектр. Голубая линия показывает модульную диагональ $f_a = f_b$; отсутствие MLP-checkpoint обобщения оставлено явным.

8. Edge-ablation и проверка переноса

Важность KAN-ребра --- RMS его вклада на всех p^2 входах. Для top, random или bottom рёбер вместе зануляются base- и spline-коэффициенты; random повторяется десять раз на модель.




Рис. 6: Изменение test accuracy относительно baseline для пяти KAN. Тонкие линии -- seed, толстые -- медиана.

Удаление 10% рёбер меняет test accuracy на -0.078 для top, -0.047 для random и 0.000 для bottom. Top сильнее bottom в 5/5 моделей, но сильнее random-медианы в 4/5: концентрация относительно bottom устойчива, утверждение ``top всегда важнее random" --- нет.

Symmetry-safe split проверяет перенос через коммутативность. В успешном random-split режиме KAN получила 8/10 classical grokking, но на symmetry-safe split --- 0/5. MLP при $p = 31$, 50% сохранила 5/5. Поэтому результат KAN чувствителен к структуре разбиения. Финальные медианы Fourier-концентрации: 0.952 для random и 0.165 для symmetry-safe. Плохое обобщение symmetry-safe KAN не позволяет трактовать их абляции как механизм успешного решения.




Рис. 7: Полные знаменатели random и symmetry-safe контролей. Условия MLP и KAN в symmetry-safe части различаются по train fraction и не образуют прямую парную ячейку; график проверяет устойчивость заявленных успешных режимов.

9. Ограничения, изменение гипотезы и вывод

Как менялась гипотеза

Exploratory-режим $p = 97$ не показал длинного плато: модель либо обобщала сразу, либо не проходила нужные фазы. После этого подтверждающая серия была зафиксирована на 31 и 53, порог 99% заменён строгой классификацией, а symmetry-safe контроль выявил зависимость эффекта от split.

Ограничения

- Сравниваются две конкретные ширины и один B-spline basis.
- Пять seed проверяют повторяемость, но широкие Wilson intervals не дают сильных популяционных выводов.
- AdamW делает сравнение контролируемым, но отделяет его от точного gradient-descent протокола Громова.
- One-hot вход ограничивает интерпретацию непрерывной формы KAN-ребра: первый слой наблюдает главным образом значения 0 и 1.
- Fourier-концентрация согласуется с модульной структурой, но не доказывает единственный внутренний алгоритм.

Вывод

Получена воспроизводимая карта фаз, а не рейтинг архитектур; сохранены все seed и отрицательные результаты. На random split KAN входит в classical grokking при меньшей доле данных, но symmetry-safe контроль показывает чувствительность этого эффекта к разбиению. Fourier и ablation дают поддерживающие свидетельства, а не доказательство единственного алгоритма.

Литература

1. Power, A. et al. *Grokking: Generalization Beyond Overfitting on Small Algorithmic Datasets*. arXiv:2201.02177, 2022.
2. Gromov, A. *Grokking modular arithmetic*. arXiv:2301.02679, 2023.
3. Nanda, N. et al. *Progress measures for grokking via mechanistic interpretability*. arXiv:2301.05217, 2023.
4. Liu, Z. et al. *KAN: Kolmogorov-Arnold Networks*. arXiv:2404.19756, 2024.
5. Park, Y.; Kim, M.; Kim, Y. *Acceleration of Grokking in Learning Arithmetic Operations via Kolmogorov-Arnold Representation*. *Neurocomputing* 640 (2025), 130347. DOI: 10.1016/j.neucom.2025.130347.